

基于学生压力与行为数据的压力水平分析报告

方一航

学号：2410306217

2026 年 7 月 5 日

1 项目概述

本项目以公开的学生压力、睡眠与屏幕时间数据集为研究对象，完成从数据读取、预处理、统计分析到机器学习建模与评估的完整数据分析流程。

项目目标包括：

- 分析学生压力水平与睡眠、屏幕使用等行为的相关性；
- 构建压力水平预测模型，识别关键影响因素；
- 将分析结果以可视化方式呈现，并搭建项目展示网页。

2 数据说明与预处理

2.1 数据集基本信息

数据集包含 500 名学生的 10 项特征，涵盖个人基本信息、生活习惯与压力状态，变量定义如下：

- 自变量：年龄、性别、睡眠时间、屏幕使用时间、学习时间、咖啡因摄入、体育活动、学业压力；
- 因变量：压力水平 (Low/Medium/High)。

数据无缺失值，质量良好，可直接用于分析。

2.2 数据预处理

为便于后续建模与可视化，对数据进行如下处理：

1. 对性别、体育活动、压力水平等分类变量进行标签编码，转为数值形式；

2. 剔除极端异常值，保证数据分布的稳定性；
3. 划分训练集与测试集，比例为 8:2，用于模型训练与评估。

3 统计分析与可视化

3.1 相关性分析

为探究各因素与压力水平的关系，计算变量间的相关系数并绘制热力图，结果如图 1 所示。




图 1: 特征相关性热力图

由热力图可知：

- 睡眠时间与压力水平呈显著负相关，睡眠越短，压力越高；
- 屏幕使用时间与压力水平呈显著正相关，屏幕使用越长，压力越高；
- 学习时间、咖啡因摄入等因素与压力水平的相关性较弱。

3.2 分组对比分析

为更直观地展示不同压力水平下的行为差异，绘制箱线图对比睡眠时间与屏幕使用时间的分布情况，结果如图 2所示。




图 2: 不同压力水平下睡眠时间与屏幕使用时间分布

从图中可以看出：

- 低压力组学生平均睡眠时间显著高于高压力组；
- 高压力组学生的平均屏幕使用时间显著高于低压力组，两者差异明显。

3.3 压力水平分布

数据集中学生压力水平分布如图 3所示，大部分学生处于中等压力水平，占比 67.6%；高压力水平学生占比 20.4%，低压力水平学生占比 12.0%。




图 3: 学生压力水平分布

4 预测模型构建与评估

4.1 模型选择与训练

本项目采用随机森林分类器构建压力水平预测模型，模型输入为学生年龄、睡眠时间、屏幕使用时间等 8 个特征，输出为压力水平。模型训练代码如下：

```
from sklearn.ensemble import RandomForestClassifier
rf = RandomForestClassifier(n_estimators=100, random_state=42)
rf.fit(X_train, y_train)
y_pred = rf.predict(X_test)
```

4.2 模型评估

模型在测试集上的准确率达到 100%，混淆矩阵如图 4 所示，所有样本均被正确分类，无预测错误。




图 4: 模型预测混淆矩阵

4.3 特征重要性分析

随机森林模型的特征重要性排序如图 5所示，结果表明，屏幕使用时间与睡眠时间是影响学生压力水平的两个最关键因素，重要性占比分别为 39.9% 和 37.5%。




图 5: 特征重要性排序

5 结论与分析

本项目通过完整的数据分析流程，得到以下结论：

1. 睡眠时间不足与屏幕使用时间过长是影响学生压力水平的核心因素；

2. 基于随机森林构建的预测模型能够准确识别学生的压力状态，为压力风险筛查提供支持；
3. 减少不必要的屏幕使用、保证充足睡眠，是缓解学生压力的有效方式。

6 项目展示网页

本项目的分析结果、代码与可视化图表已上传至 GitHub Pages 个人主页，可通过以下网址访问：

`https://fyh006.github.io`